

- ▼ 1.使用准备
  - 1.1 python下载与安装
  - ▼ 1.2 编辑器下载
    - 1.2.1 PyChram下载
    - 1.2.2 VScode下载、安装与配置
  - ▼ 1.3第三方库的下载与安装
    - 1.3.1使用终端/terminal安装第三方库
    - 1.3.2使用PyCharm安装第三方库
  - 1.4打开程序
- ▼ 2.开始使用
  - ▼ 2.1训练模型
    - 2.1.1检查是否有缺失值
    - 2.1.2修改参数
    - 2.1.3 结果查看
  - ▼ 2.2.保存模型
    - 2.2.1 修改参数
    - 2.2.2 结果查看
  - ▼ 2.3使用模型预测
    - 2.3.1修改文件路径
    - 2.3.2修改函数
    - 2.3.3结果查看
  - ▼ 2.4可视化决策树与打印分类条件
    - 2.4.1修改文件路径
    - 2.4.2修改参数

# 1.使用准备

## 1.1 python下载与安装

有关python下载与安装请见[Python的下载安装教程](#)

## 1.2 编辑器下载

编辑器可用于修改与运行代码，这里提供了PyCharm与VScode的下载与安装两种方法

## 1.2.1 PyCharm下载

有关PyCharm下载与安装请见[PyCharm安装教程](#)

## 1.2.2 VScode下载、安装与配置

有关VScode下载与安装请见[用VScode配置Python开发环境](#)

# 1.3第三方库的下载与安装

在本程序中使用了numpy、pandas、sklearn库，在运行程序前请确保您已经下载并安装了所有需要的第三方库，这里提供了从终端中安装与从PyCharm中安装两种方法

## 1.3.1使用终端/terminal安装第三方库

1. 使用 `win+R` 打开'运行'对话框。
2. 在对话框中输入·cmd·， 点击确定
3. 分行输入以下代码

注：一次仅输入一行，运行完成后再按顺序输入下一行。

```
pip install numpy
pip install pandas
pip install scipy
pip install matplotlib
pip install scikit_learn
pip install openpyxl
pip install xlswriter
pip install joblib
pip install graphviz
```

注：如果 graphviz 安装出错，请见[安装graphviz](#)

如果发生网络错误，试试以下换源代码

```
pip install [第三方库名] --trusted-host pypi.mirrors.ustc.edu.cn/simple # 中科大源
pip install [第三方库名] --trusted-host pypi.tuna.tsinghua.edu.cn/simple # 清华源
```

## 1.3.2使用PyCharm安装第三方库

有关使用PyCharm下载安装第三方库请见[安装第三方库的四种方法](#)

## 1.4打开程序

打开编辑器，点击左上角的File，再点击Open，选择文件夹所在的位置，点击确定。

## 2.开始使用

请注意:请将数据以.xlsx格式保存，包含n个特征列与1个标签列。以下操作均使用 data 文件夹下的 j.xlsx 文件为例，该文件共包含39列，其中第1-38列为特征，第39列为标签。每一次运行结束后，请及时将 # 恢复，以免影响下一步操作。

在每一步开始前，请检查文件路径及 file\_name，file\_name 为以后输出图像，模型，结果的文件名，这里设置为 小学生

### 2.1训练模型

以下涉及到不同的算法部分操作均以 programs 文件夹下的 dt\_Classiffication\_Sklearn.py 为例

#### 2.1.1检查是否有缺失值

在 programs 文件夹下的 if\_miss.py 中进行

##### 1. 修改文件路径

将 file = 'E:\\Classiffication\_Models\\real\\p.xlsx' 修改为当前 p.xlsx 文件所在的绝对路径

##### 2. 运行程序 if\_miss.py

3. 如果每一行最后数值均为0，则无缺失值，进入下一节。若不为零，则存在缺失值，请检查文件。

#### 2.1.2修改参数

在 programs 文件夹下的 main.py 中进行

1. 将 file = 'E:\\Classiffication\_Models\\real\\p.xlsx' 修改为当前 p.xlsx 文件所在的绝对路径

2. 打开 main.py，找到：

```
# parameters:
criteria=[ 'gini', 'entropy', 'log_loss']
max_depths=[2,3,4,5,6,7,8,9,10]
min_samples_splits=[5,10,20,25,30,40,50,60,100,200,300]
```

通过修改列表/list（中括号）中的字符串、元组/tuple（小括号）、整数或小数来得到不同的参数组合以得到不同的结果。

### 3. 修改 main() 找到

```
def main():  
  
    # train the models:  
    #loop_dt(file,file_name,test_sizes,criterions, max_depths, min_samples_splits)
```

这里可以控制运行那些算法，将loop\_dt()前的 # 删除。

### 4. 运行程序 main.py

## 2.1.3 结果查看

由于此处我们仅运行了dt,因此只会出现一个 小学生.xlsx 的文件。包含各个参数组合及运行结果。

## 2.2.保存模型

开始保存模型之前，请您确保您已经确认数据文件无缺失值，并且已经将 file 修改为您当前的数据保存路径

### 2.2.1 修改参数

在 programs 文件夹下的 main.py 中进行，建议执行此步骤之前，通过2.1得到最佳参数组合。

1. 打开 main.py ,将 file = 'E:\\Classiffication\_Models\\DecisionTree-v1.0.0\\data\\p.xlsx 修改为当前 p.xlsx 文件所在的绝对路径
2. 打开 main.py , 找到:

```
# parameters:  
criterions=['gini', 'entropy', 'log_loss']  
max_depths=[2,3,4,5,6,7,8,9,10]  
min_samples_splits=[5,10,20,25,30,40,50,60,100,200,300]
```

通过修改列表/list（中括号）中的字符串、元组/tuple（小括号），将其修改为2.1.3中得到的最佳的参数组合。若在一个列表中保留多个，程序会自动执行列表中的第一个参数。注意，保存模型时是使用全部数据训练，因此无需修改 test\_sizes

### 3. 修改 main()

找到

```
# save the models:
#save_dt(file,file_name,criterions[0], max_depths[0], min_samples_splits[0])
```

将 `#save_dt(file,file_name,criterions[0], max_depths[0],min_samples_splits[0])` 前的 `#` 删除

### 4. 运行程序 main.py

## 2.2.2 结果查看

由于此处我们仅运行了 `save_dt()` ,因此只会出现一个 `dt_model.joblib` 的文件。请将其保存在 `saved_models` 文件夹下。

## 2.3使用模型预测

这里使用 `data` 文件夹下的 `test_p.xlsx` 文件作为例子, 请注意: `test_p.xlsx` 文件的格式应当和 `data` 文件夹下的 `p.xlsx` 保持一致, 除了没有标签列.

这里也可以使用 `main()` 中的

```
# predict
#dt_predict(predict_file,dt_model)
```

方法

### 2.3.1修改文件路径

#### 1. 打开 datapredict.py

找到

```
predict_file = 'E:\\Classiffication_Models\\Classiffication_Models-v1.2.1\\data\\test_p.xlsx'

dt_model = 'E:\\Classiffication_Models\\Classiffication_Models-v1.2.1\\saved_models\\小学生.joblib'
```

将 `predict_file` 与 `dt_model` 文件分别更改为 `test_p.xlsx` 与 `小学生.joblib` 的绝对路径

### 2.3.2修改函数

#### 1. 打开 datapredict.py

## 2. 修改参数

找到

```
# predict
#dt_predict(predict_file,dt_model)
#svm_predict(predict_file,svm_model)
#rf_predict(predict_file,rf_model)
#knn_predict(predict_file,knn_model)
#stack_predict(predict_file,stack_model)
```

将 #dt\_predict(predict\_file,dt\_model) 前的 # 删去

## 3. 运行 datapredict.py

### 2.3.3结果查看

运行结果将会保存在 data 文件夹下的 test\_p.xlsx 文件的 dt\_pred 工作表中

## 2.4可视化决策树与打印分类条件

注：请将列名更改为英文或拼音

### 2.4.1修改文件路径

#### 1. 打开 main.py

找到：

```
file = 'E:\\Classiffication_Models\\DecisionTree-v1.0.0\\data\\p.xlsx'
predict_file = 'E:\\Classiffication_Models\\DecisionTree-v1.0.0\\data\\test_p.xlsx'
dt_model = 'E:\\Classiffication_Models\\DecisionTree-v1.0.0\\saved_models\\小学生.joblib'

file_name = '小学生'
```

2. 将 file = 'E:\\Classiffication\_Models\\real\\p.xlsx' 修改为当前 p.xlsx 文件所在的绝对路径，  
将 file\_name 修改为需要输出的文件名

### 2.4.2修改参数

在 programs 文件夹下的 main.py 中进行

1. 将 file = 'E:\\Classiffication\_Models\\real\\p.xlsx' 修改为当前 p.xlsx 文件所在的绝对路径
2. 打开 main.py , 找到：

```
# parameters:
criteria=[ 'gini', 'entropy', 'log_loss']
max_depths=[2,3,4,5,6,7,8,9,10]
min_samples_splits=[5,10,20,25,30,40,50,60,100,200,300]
```

通过修改列表/list（中括号）中的字符串、元组/tuple（小括号）、整数或小数来得到不同的参数组合以得到不同的结果。

### 3. 修改 main() 找到

```
def main():

    # train the models:
    #loop_dt(file,file_name,test_sizes,criteria, max_depths, min_samples_splits)

    # save the models:
    #save_dt(file,file_name,criteria[0], max_depths[0], min_samples_splits[0])

    # Visualize
    #plot_dt(file,file_name,criteria[0], max_depths[0], min_samples_splits[0])

    # predict
    #dt_predict(predict_file,dt_model)

    #print
    #print_dt(file,criteria[0], max_depths[0], min_samples_splits[0])
```

这里可以控制运行那些算法，将plot\_dt()与print\_dt前的 # 删除。

plot\_dt()生成决策树的图像，以pdf格式保存，print\_dt打印出每一个类的判定条件，在终端输出